



Centro Universitário Álvares Penteado
Projeto Interdisciplinar: Ciência de Dados

1ª Entrega PI: Relatório de Exploração

Objetivo: Realizar um relatório que consiga identificar a fonte dos dados, descrever os dados explorá-los.

Nomes:

Julia Pereira Godinho | RA: 26028796
Mariana Almeida Nascimento | RA: 22011051
Rafaela Florêncio Moraes | RA: 25027460

Profº Eduardo
Savino Gomes

Turma: CCOMP
4

Objetivo

Este documento tem como objetivo apresentar e documentar as etapas realizadas no desenvolvimento da primeira entrega da disciplina de Projeto Interdisciplinar: Ciência de Dados do curso de Ciência da Computação, desenvolvido em parceria com a CTI Global. O relatório descreve o processo de obtenção, compreensão, exploração, seleção, limpeza, transformação e organização dos dados financeiros utilizados no projeto.

Além de registrar os procedimentos realizados sobre a base de dados, o documento apresenta os principais resultados obtidos durante o tratamento dos dados, estabelecendo uma base estruturada e adequada para as próximas etapas do projeto, incluindo a análise inferencial dos dados, a construção de indicadores e desenvolvimento do dashboard analítico.

1. Introdução

A transformação de dados financeiros em informações úteis para a tomada de decisão é um dos principais desafios enfrentados por organizações que trabalham com planejamento e análise financeira. Nesse contexto, o projeto interdisciplinar desenvolvido em parceria com a CTI Global propõe a utilização de técnicas de

Ciência de Dados para organizar, analisar e transformar dados financeiros em informações que possam apoiar a compreensão de diferentes cenários.

O projeto utiliza uma base de dados financeiros projetados a partir de uma **simulação de Monte Carlo de uma empresa de concessão**. A base contempla diferentes possibilidades de comportamento financeiro da empresa, representadas por cenários simulados ao longo de um horizonte de 12 anos. Os dados estão organizados por ano, cenário e conta financeira, abrangendo informações relacionadas ao Balanço Patrimonial (BAL), à Demonstração do Resultado do Exercício (DRE) e ao Fluxo de Caixa (FLU).

Nesta primeira etapa do projeto, o foco está na preparação e organização dos dados. O processo envolve as etapas de coleta, descrição, exploração, seleção, limpeza, transformação e integração, buscando garantir uma base estruturada e adequada para as análises posteriores. A partir dessa preparação, serão desenvolvidos indicadores financeiros, análises comparativas entre cenários e, posteriormente, um dashboard analítico para apoiar a interpretação dos resultados.

2. Identificação da fonte de dados

A fonte de dados utilizada neste projeto foi uma base financeira disponibilizada no contexto da parceria com a CTI Global, fornecida em formato CSV com o nome Demonstrativo Fecap v3.csv.

A base representa dados financeiros projetados por meio de uma simulação de Monte Carlo de uma empresa de concessão, permitindo a análise de diferentes cenários possíveis para o comportamento financeiro da empresa ao longo do tempo. Os dados estão organizados por ano, cenário e conta financeira, contemplando informações do Balanço Patrimonial (BAL), da Demonstração do Resultado do Exercício (DRE) e do Fluxo de Caixa (FLU).

O arquivo original foi mantido na pasta data/raw do projeto, preservando a fonte de dados sem alterações. Essa organização permite manter a rastreabilidade dos dados e separar a base original das etapas posteriores de tratamento, transformação e análise.

3. Coleta de dados iniciais

A leitura da base foi realizada no ambiente Jupyter Notebook, utilizando a linguagem Python e a biblioteca Pandas. Durante a importação, foram considerados o separador utilizado no arquivo e a codificação dos caracteres, além da definição dos nomes das colunas para organizar corretamente os dados.

Após a leitura, a base foi inicialmente inspecionada para verificar sua estrutura e confirmar o correto carregamento das informações. Foram identificados os campos **Ano, Cenário, Conta e Valor**, que posteriormente foram utilizados nas etapas de exploração, seleção e tratamento dos dados.

4. Descrição dos dados

A base de dados é composta por quatro campos principais: Ano, Cenário, Conta e Valor. Esses campos permitem representar os dados financeiros de acordo com o período analisado, o cenário simulado e a respectiva conta financeira.

Ano	Identifica o período da projeção financeira, abrangendo do Ano 1 ao Ano 12.
Cenário	Identifica os diferentes cenários gerados pela simulação, totalizando 1.200 cenários.
Conta	Identifica a conta ou categoria financeira associada ao registro.
Valor	Representa o valor financeiro associado a determinada conta, cenário e ano.

A base original possui 1.002.000 registros, distribuídos entre 12 anos e 1.200 cenários. As informações financeiras estão relacionadas a três grupos principais: **Balanco Patrimonial (BAL)**, **Demonstração do Resultado do Exercício (DRE)** e **Fluxo de Caixa (FLU)**. A organização desses dados permite realizar análises considerando tanto a evolução financeira ao longo dos anos quanto as diferenças entre os cenários simulados.

5. Exploração dos dados

A etapa de exploração dos dados teve como objetivo compreender a estrutura da base, identificar padrões e verificar possíveis inconsistências antes da realização das etapas de seleção e tratamento.

Inicialmente, foram analisadas as dimensões da base, a distribuição dos registros entre os anos e cenários e os tipos de dados presentes nas colunas. A análise identificou **1.002.000 registros**, distribuídos entre **12 anos e 1.200 cenários**, permitindo verificar a abrangência da simulação.

Também foi realizada a análise dos valores ausentes. Foram identificados registros sem informação na coluna **Conta**. Durante a exploração, verificou-se que essas ocorrências possuem uma característica estrutural da própria base, estando relacionadas a parâmetros utilizados na organização dos dados da simulação. Dessa forma, esses registros não foram considerados automaticamente como erros. Foram ainda analisadas as contas financeiras disponíveis e sua distribuição entre os grupos **BAL**, **DRE** e **FLU**, além dos valores financeiros presentes na base. Essa exploração permitiu compreender quais informações poderiam ser utilizadas nas análises posteriores e orientar a seleção das contas mais relevantes para os objetivos do projeto.

A etapa de exploração foi fundamental para conhecer as características da base antes da aplicação dos procedimentos de limpeza, seleção, transformação e integração dos dados.

6. Seleção dos dados

Após a exploração da base, foi realizada a seleção das informações consideradas mais relevantes para os objetivos do projeto. O processo teve como finalidade reduzir a

quantidade de dados analisados, mantendo as contas financeiras necessárias para a realização das análises e para a construção dos indicadores do dashboard.

Foram selecionadas **24 contas financeiras**, distribuídas entre os três principais grupos da base: **Balanço Patrimonial (BAL)**, **Demonstração do Resultado do Exercício (DRE)** e **Fluxo de Caixa (FLU)**.

No grupo BAL, foram selecionadas contas relacionadas à estrutura patrimonial, como Ativo Circulante, Disponível, Estoques, Passivo Circulante, Patrimônio Líquido, Permanente e empréstimos. No grupo DRE, foram selecionadas contas relacionadas à geração de resultados, como Receita, Tributos, Custos, Resultado Líquido, Receitas e Despesas Financeiras e EBITDA. Já no grupo FLU, foram selecionadas contas relacionadas à movimentação de caixa, como Geração de Caixa, Investimentos, Saldo Inicial e Saldo Final.

A seleção resultou em uma base com **340.800 registros**, abrangendo os **12 anos** e os **1.200 cenários** disponíveis. Algumas contas selecionadas não apresentam registros no Ano 12, característica estrutural da base original que foi preservada durante o tratamento, sem a criação artificial de valores.

A seleção dessas contas permite concentrar as etapas posteriores nas informações mais relevantes para a análise financeira, possibilitando a comparação entre cenários e anos e a criação de indicadores para o dashboard.

7. Limpeza e uniformização dos dados

Após a seleção das informações, foi realizada a etapa de limpeza e uniformização da base, com o objetivo de garantir que os dados estivessem estruturados de forma adequada para as análises posteriores.

Inicialmente, foi realizada a padronização dos nomes das contas, removendo espaços em excesso que poderiam gerar diferenças entre registros que representavam a mesma conta financeira.

Por exemplo, a conta originalmente registrada como **BAL - Patrimônio Líquido**, contendo dois espaços entre BAL e o hífen, foi padronizada para **BAL - Patrimônio Líquido**. Essa transformação evitou que a mesma conta fosse interpretada como categorias diferentes durante a seleção dos dados.

Também foi verificada a existência de valores ausentes na base selecionada. Após a seleção das contas utilizadas no projeto, não foram identificados valores nulos nos campos Ano, Cenário, Conta e Valor.

Outro tratamento importante foi realizado na coluna Valor. Originalmente, os valores estavam armazenados como texto e utilizavam o padrão numérico brasileiro, no qual o ponto representa o separador de milhares e a vírgula representa o separador decimal. Por exemplo:

Antes: 1.795.720.872,18

Depois: 1795720872.18

Para realizar essa transformação, foram removidos os pontos utilizados como separadores de milhares, a vírgula decimal foi substituída por ponto e, posteriormente, o campo foi convertido para o tipo numérico float64. Essa alteração permitiu a realização de operações matemáticas, cálculos de indicadores e análises estatísticas.

Durante a análise dos valores, foram identificados **129.150 registros com valores negativos** e **2.112 registros com valor igual a zero**. Esses valores foram

mantidos, pois podem representar situações financeiras válidas. Como exemplos, valores negativos aparecem em contas como DRE - Custos, DRE - Tributos, DRE - Despesas Financeiras e FLU - Investimentos, enquanto os valores iguais a zero foram identificados na conta DRE - Receitas Financeiras.

Também foram analisados os valores extremos presentes na base. O menor valor identificado foi de aproximadamente **-R\$ 8,89 bilhões**, registrado em BAL - Patrimônio Líquido no Ano 11 do cenário Total Cen_01128. O maior valor foi de aproximadamente **R\$ 14,59 bilhões**, registrado em DRE - Receita no Ano 12 do mesmo cenário. Esses valores foram mantidos, pois não foram identificados, nesta etapa, elementos suficientes para classificá-los como erros de registro.

Por fim, foi realizada a verificação de duplicidades na base selecionada, não sendo encontradas duplicatas exatas. As ausências estruturais identificadas anteriormente também foram preservadas, sem preenchimento artificial de valores. Entre elas, estão as contas BAL - Emprést, BAL - Estoques Diversos, BAL - Exigível a Longo Prazo e BAL - Patrimônio Líquido, que não apresentam registros no Ano 12. Dessa forma, o tratamento buscou corrigir problemas de padronização e formato sem alterar informações financeiras que poderiam representar características reais da simulação.

8. Derivação e integração dos dados

Após as etapas de seleção e limpeza, os dados foram reorganizados para facilitar a realização das análises financeiras. A base selecionada estava inicialmente estruturada em formato longo, com cada registro representando uma combinação entre ano, cenário, conta e valor.

Para tornar os dados mais adequados às análises, foi realizada uma transformação para o formato analítico. Nesse processo, **Ano e Cenário** foram utilizados como identificadores, enquanto as contas financeiras passaram a ser organizadas como colunas. Dessa forma, cada linha passou a representar um determinado cenário em um determinado ano, concentrando suas respectivas informações financeiras.

Por exemplo, registros originalmente apresentados separadamente:

Ano	Cenário	Conta	Valor
Ano 1	Total Cen_00001	DRE - Receita	R\$ 6.722.729.306,39
Ano 1	Total Cen_00001	DRE – EBITDA	R\$ 5.188.380.666,78
Ano 1	Total Cen_00001	BAL – Ativo Circulante	R\$ 1.795.720.872,18

passaram a ser organizados em uma única linha do cenário, com cada conta representada por uma coluna.

Exemplo da base após a integração

A estrutura final permite visualizar diversas informações financeiras de um mesmo cenário na mesma linha:

Ano	Cenário	Receita	EBITDA	Resultado do Líquido	AC	PC	Margem EBITDA	Margem Líquida	Capital de Giro
Ano 1	Total Cen_00001	R\$ 6,72 bi	R\$ 5,19 bi	—	R\$ 1,80 bi	—	77,17%	36,34%	R\$ 2,88 bi

Exemplo ilustrativo da estrutura da base integrada. A tabela apresenta apenas algumas das 29 colunas existentes.

Além da reorganização dos dados, foram criados três indicadores derivados para ampliar a capacidade de análise financeira da base:

Margem EBITDA

A Margem EBITDA foi calculada pela relação entre o EBITDA e a Receita:

$$\text{Margem EBITDA} = (\text{EBITDA} / \text{Receita}) \times 100$$

Esse indicador permite analisar a participação do EBITDA em relação à receita obtida no cenário analisado.

Margem Líquida

A Margem Líquida foi calculada pela relação entre o Resultado Líquido e a Receita:

$$\text{Margem Líquida} = (\text{Resultado Líquido} / \text{Receita}) \times 100$$

O indicador permite observar a proporção do resultado líquido em relação à receita.

Capital de Giro

O Capital de Giro foi calculado pela diferença entre o Ativo Circulante e o Passivo Circulante:

$$\text{Capital de Giro} = \text{Ativo Circulante} - \text{Passivo Circulante}$$

Esse cálculo permite analisar a diferença entre os recursos de curto prazo e as obrigações de curto prazo da empresa.

Ao final da etapa de derivação e integração, a base passou a possuir 14.400 registros e 29 colunas, sendo 2 colunas de identificação, 24 contas financeiras selecionadas e 3 indicadores derivados. Essa estrutura servirá como base para as análises financeiras e para o desenvolvimento dos indicadores utilizados no dashboard.

9. Formatação dos dados

Após a conclusão das etapas de seleção, limpeza, transformação e integração, foi realizada a formatação final da base de dados. Essa etapa teve como objetivo organizar a estrutura dos dados de maneira padronizada e adequada para sua utilização nas etapas posteriores do projeto, especialmente nas análises financeiras, construção de indicadores e desenvolvimento do dashboard.

A primeira ação realizada foi a padronização dos nomes das colunas. Os nomes das contas financeiras, que originalmente continham espaços e caracteres de separação, foram convertidos para uma estrutura mais adequada à manipulação em Python. Os espaços foram substituídos pelo caractere _ e os separadores presentes nos nomes das contas foram padronizados. Por exemplo, a variável **BAL - Ativo Circulante** passou a ser identificada como **BAL_Ativo_Circulante**, enquanto **DRE - Resultado Líquido** passou a ser **DRE_Resultado_Líquido**.

Essa padronização facilita a utilização das variáveis durante a programação, principalmente em operações de seleção, cálculos, criação de indicadores e visualizações. Além disso, reduz a possibilidade de erros causados por diferenças de nomenclatura e torna a estrutura da base mais consistente.

Também foi realizada a organização dos tipos de dados. As informações financeiras foram mantidas em formato numérico float64, permitindo que os valores fossem utilizados diretamente em operações matemáticas, cálculos estatísticos e construção de indicadores. Já as variáveis Ano e Cenário permaneceram como texto, pois são utilizadas como identificadores e categorias de agrupamento.

A estrutura final da base foi organizada de forma que cada registro correspondesse à combinação de um determinado ano e cenário, enquanto as contas financeiras passaram a ocupar colunas específicas. Essa organização permite consultar diferentes informações financeiras de um mesmo cenário de forma conjunta e facilita operações como agrupamentos, comparações entre anos e análises entre cenários.

Após todas as transformações, a base final apresentou **14.400 registros e 29 colunas**. Essa estrutura é composta por:

Componente	Quantidade	Descrição
Identificação	2	Ano e Cenário
Contas financeiras	24	Contas selecionadas dos grupos BAL, DRE e FLU
Indicadores derivados	3	Margem_EBITDA, Margem_Líquida e Capital_de_Giro
Total	29	Estrutura final da base integrada

As ausências estruturais identificadas durante as etapas anteriores foram preservadas na base final, sem a criação artificial de valores. Essa decisão buscou manter a fidelidade às características originais da simulação e evitar que informações não existentes fossem introduzidas durante o tratamento.

Como resultado, a base passou a apresentar uma estrutura padronizada, organizada e adequada para as próximas etapas do projeto. A partir dessa versão formatada, os dados podem ser utilizados de maneira mais eficiente para a realização das análises financeiras, comparação dos cenários simulados, acompanhamento da evolução ao longo dos 12 anos e desenvolvimento dos indicadores que serão posteriormente apresentados no dashboard.

10. Considerações finais

A realização desta primeira etapa do projeto possibilitou estruturar e preparar uma base de dados financeiros proveniente de uma simulação de Monte Carlo de uma empresa de concessão, criando condições para que os dados possam ser utilizados de forma mais consistente nas etapas seguintes do projeto. Ao longo do desenvolvimento, foram realizadas as etapas de identificação da fonte, coleta, descrição, exploração, seleção, limpeza, uniformização, derivação, integração e formatação dos dados.

Durante esse processo, foi possível compreender as características da base, composta por **1.002.000 registros, 12 anos e 1.200 cenários**, além de identificar particularidades importantes, como valores negativos, valores iguais a zero, ausências estruturais e diferenças de formatação nos nomes das contas. O tratamento dessas características foi realizado buscando preservar as informações originais da simulação e evitar alterações ou preenchimentos que pudessem comprometer a interpretação dos dados.

A seleção das informações permitiu concentrar a análise em **24 contas financeiras** dos grupos BAL, DRE e FLU, consideradas relevantes para os objetivos do projeto. A partir dessas informações, os dados foram reorganizados em uma estrutura analítica com **14.400 registros e 29 colunas**, incluindo os indicadores derivados de Margem EBITDA, Margem Líquida e Capital de Giro. Dessa forma, a primeira entrega estabeleceu uma base estruturada, tratada e documentada para o desenvolvimento das próximas etapas. A organização dos dados permitirá avançar para análises financeiras mais aprofundadas, comparação entre os diferentes cenários simulados, identificação de padrões e construção de novos indicadores.

Próximos passos

Como continuidade do projeto, serão desenvolvidas novas análises sobre a base estruturada, buscando explorar o comportamento dos indicadores financeiros ao longo dos anos e entre os diferentes cenários da simulação. Nessa etapa, poderão ser realizadas análises descritivas e inferenciais, permitindo identificar padrões, relações entre variáveis e diferenças relevantes nos resultados financeiros.

Também serão desenvolvidos novos indicadores e métricas financeiras, de acordo com os objetivos definidos para o projeto, ampliando a capacidade de interpretação dos dados e possibilitando análises relacionadas a aspectos como receita, custos, margem, geração de caixa e desempenho financeiro.

Posteriormente, os resultados obtidos serão utilizados na construção do dashboard analítico, que deverá apresentar os principais indicadores de forma visual e interativa. O dashboard contará com recursos de filtragem e comparação entre anos e cenários, permitindo uma exploração mais dinâmica das informações.

Por fim, serão realizadas as etapas de validação dos indicadores, documentação dos resultados e disponibilização da solução em ambiente de visualização. Dessa forma, o projeto avançará da preparação e estruturação dos dados para a transformação dessas informações em análises e recursos visuais capazes de apoiar o planejamento e a interpretação financeira da empresa simulada.

