Entrega 02: Relatório de Análise de Regressão dos Dados

Objetivo: ajustar um modelo de regressão linear para explorar relações entre indicadores financeiros, interpretar os coeficientes, avaliar a qualidade do ajuste e registrar as limitações da análise.

Nomes:
Julia Pereira Godinho | RA: 26028796
Mariana Almeida Nascimento | RA: 22011051
Rafaela Florêncio Morais | RA: 25027460

Professor:
Prof° Rodnil Lisboa

Turma:
CCOMP 4

Objetivo

Este documento apresenta a segunda entrega da disciplina de Análise Inferencial de Dados, cujo objetivo é conduzir uma análise de regressão sobre os dados financeiros do projeto, dando sequência à análise descritiva realizada na entrega anterior. O relatório descreve a escolha das variáveis do modelo, o ajuste da regressão linear, a interpretação dos coeficientes, a avaliação da qualidade do ajuste, os diagnósticos realizados sobre os resíduos e as limitações identificadas.

1. Escolhendo as variáveis do modelo

Antes de ajustar qualquer modelo, foi feita uma análise de correlação entre os principais indicadores financeiros para evitar um erro comum: montar uma regressão entre variáveis que são, na prática, quase a mesma coisa escrita de formas diferentes.

Par de variáveis	Correlação	Leitura
Receita x EBITDA	0,990	muito alta, quase identidade contábil
Receita x Resultado Líquido	0,992	muito alta, quase identidade contábil
Resultado Líquido x Geração de Caixa	-0,460	moderada e negativa, relação real a explorar
Ano x Geração de Caixa	-0,172	fraca, mas com padrão não linear ao longo da concessão

Receita, EBITDA e Resultado Líquido se correlacionam entre si acima de 0,99. Isso é esperado pela própria estrutura da demonstração de resultado: o EBITDA deriva da Receita e o Resultado Líquido deriva do EBITDA, então os três crescem praticamente juntos ao longo dos 12 anos da concessão. Usar uma dessas variáveis para prever outra resultaria em um R^2 artificialmente próximo de 1, sem revelar relação nenhuma, apenas reconstruindo uma identidade contábil.

A Geração de Caixa, por outro lado, apresenta uma correlação moderada e negativa com o Resultado Líquido e uma correlação fraca com o Ano, um padrão bem diferente do observado entre Receita, EBITDA e Resultado Líquido. Isso indica que a Geração de Caixa segue uma lógica própria, provavelmente ligada a itens que não passam diretamente pelo resultado contábil, como

capital de giro e o momento dos desembolsos de caixa. Por esse motivo, o modelo escolhido para esta entrega foi:

$$\textbf{\textit{Geração de Caixa} = } \beta_0 + \beta_1 \times \textbf{\textit{Resultado Líquido}} + \beta_2 \times \textbf{\textit{Ano}} + \textbf{\textit{erro}}$$

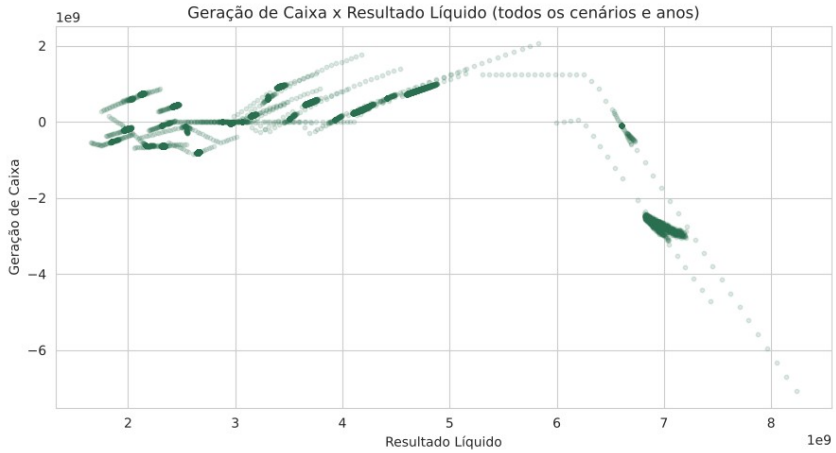


Figura 1. Geração de Caixa em função do Resultado Líquido, todos os cenários e anos.

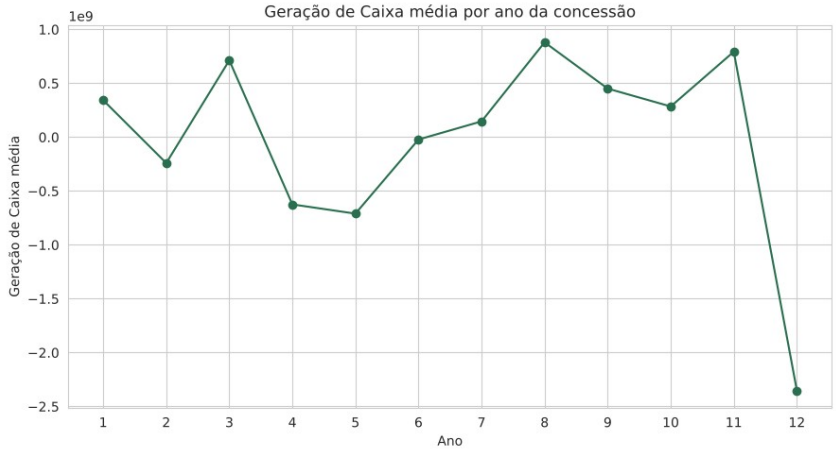


Figura 2. Geração de Caixa média por ano da concessão.

A Figura 1 mostra uma nuvem de pontos com inclinação negativa, mas bem mais espalhada do que seria o caso entre Receita, EBITDA e Resultado Líquido. A Figura 2 mostra que a geração de caixa média cresce ao longo da concessão, com queda nos últimos anos, quando o contrato está se encerrando, o que justifica incluir o Ano como segunda variável explicativa.

2. Ajustando o modelo e interpretando os coeficientes

Com as variáveis definidas, o modelo foi ajustado por mínimos quadrados ordinários (OLS), usando as 14.400 observações da base (1.200 cenários x 12 anos).

Variável	Coeficiente	P-valor	VIF
Intercepto	1,34 bi	-	-
Resultado Líquido	-0,928	< 0,0001	4,37
Ano	269,0 mi	< 0,0001	4,37

O intercepto não tem leitura prática isolada, serve apenas para ancorar a reta quando as demais variáveis são zero, algo que não ocorre nos dados reais. O coeficiente do Resultado Líquido indica que, mantendo o ano fixo, cada real a mais de resultado líquido está associado, em média, a uma redução de cerca de 0,93 real na geração de caixa. Já o coeficiente do Ano indica que, mantido o resultado líquido fixo, cada ano adicional de concessão está associado a um aumento médio de aproximadamente 269 milhões de reais na geração de caixa.

O sinal negativo do Resultado Líquido chama atenção, porque seria razoável esperar que mais lucro significasse mais caixa gerado. Esse resultado é, provavelmente, um reflexo do mesmo cuidado identificado na entrega anterior ao analisar a dispersão dos indicadores: quando o modelo usa todos os anos e cenários agrupados, parte do que parece ser o efeito do Resultado Líquido é, na verdade, o efeito do tempo passando. Receita, EBITDA e Resultado Líquido crescem de forma quase determinística ano a ano, enquanto a Geração de Caixa tem uma dinâmica diferente, com picos em certos anos e queda no fim da concessão. Ao tentar separar o efeito do Ano do efeito do Resultado Líquido, o modelo acaba atribuindo um coeficiente negativo ao Resultado Líquido para compensar o forte efeito positivo do Ano. Ainda assim, os dois coeficientes são estatisticamente significativos, o que indica que a relação não é fruto do acaso dentro da amostra, mesmo que a leitura causal exija cautela.

3. Qualidade do ajuste

O modelo apresentou R^2 de 0,447 e R^2 ajustado de 0,447, ou seja, explica cerca de 45% da variação da Geração de Caixa a partir do Resultado Líquido e do Ano. O teste F (estatística = 5.814,2, p-valor < 0,0001) confirma que o modelo como um todo é estatisticamente significativo.

É um ajuste moderado: nem perto de 1, o que seria sinal de uma identidade contábil disfarçada (como ocorreria ao usar EBITDA no lugar do Resultado Líquido), nem perto de zero, o que indicaria ausência de relação. Pouco mais da metade da variação da Geração de Caixa fica fora do que as duas variáveis explicam, o que é esperado, já que a geração de caixa também depende de fatores como variação de capital de giro, descompasso entre pagamentos e recebimentos, e decisões específicas de cada cenário simulado.

3.1 Testes de hipótese sobre o modelo

A regressão também pode ser lida como um conjunto de testes de hipótese. Para cada coeficiente, o teste t tem como hipótese nula (H0) que o coeficiente é zero, isto é, que a variável não ajuda a explicar a Geração de Caixa com a outra variável mantida fixa, e como hipótese alternativa (H1) que o coeficiente é diferente de zero. A estatística t é o coeficiente dividido pelo seu erro-padrão, e H0 é rejeitada quando o valor-p é menor que 0,05. Para o modelo como um todo, o teste F tem como H0 que todos os coeficientes, exceto o intercepto, são zero.

Variável	Estatística t	Valor-p	IC 95%	Decisão
Resultado Líquido	-104,2	< 0,0001	[-0,945; -0,910]	rejeita H0
Ano	78,3	< 0,0001	[262,2 mi; 275,7 mi]	rejeita H0

Variável	Estatística t	Valor-p	IC 95%	Decisão
Modelo (teste F)	5.814,2	< 0,0001	-	rejeita H0

Nos dois testes t o valor-p é praticamente zero, então H0 é rejeitada para o Resultado Líquido e para o Ano, e os intervalos de confiança de 95% não incluem o zero. O teste F também rejeita H0, logo o modelo explica mais do que apenas a média da Geração de Caixa. Com 14.400 observações, porém, até efeitos pequenos produzem valores-p minúsculos, por isso o valor-p deve ser lido junto com o tamanho do efeito e o R^2. Como os diagnósticos a seguir mostram que as premissas do OLS não são totalmente atendidas, esses valores-p devem ser tratados como aproximados.

4. Diagnósticos do modelo

Além do R^2 e dos coeficientes, foram verificadas as premissas clássicas da regressão linear: linearidade, variância constante, normalidade e independência dos resíduos.

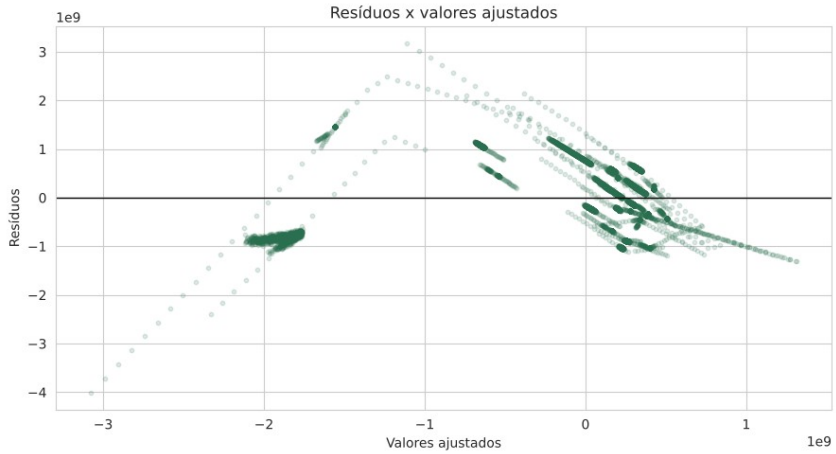


Figura 3. Resíduos em função dos valores ajustados.

Em um modelo bem especificado, essa nuvem de pontos deveria se espalhar de forma uniforme ao redor da linha zero, sem padrão aparente. Aqui é possível notar uma leve curvatura e um espalhamento que muda conforme o valor ajustado, indícios de que a relação não é perfeitamente linear e de que a variância dos resíduos não é constante.

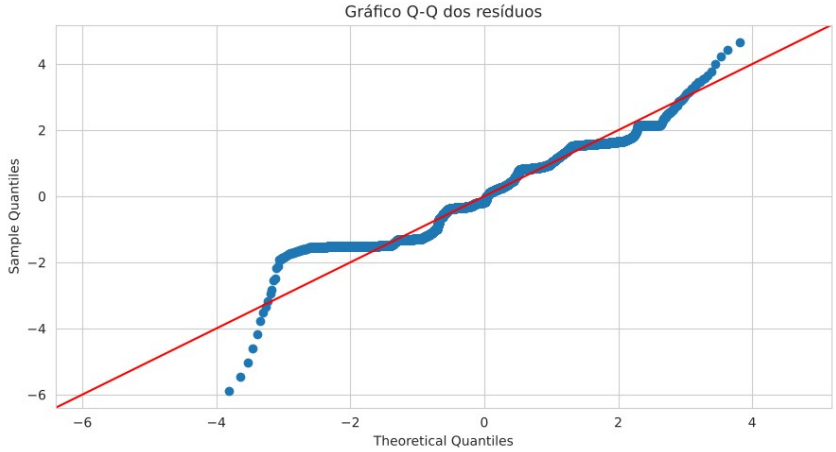


Figura 4. Gráfico Q-Q dos resíduos.

No gráfico Q-Q, resíduos normalmente distribuídos ficariam sobre a linha diagonal. Aqui os pontos se afastam da linha principalmente nas extremidades, indicando caudas mais pesadas do que uma distribuição normal.

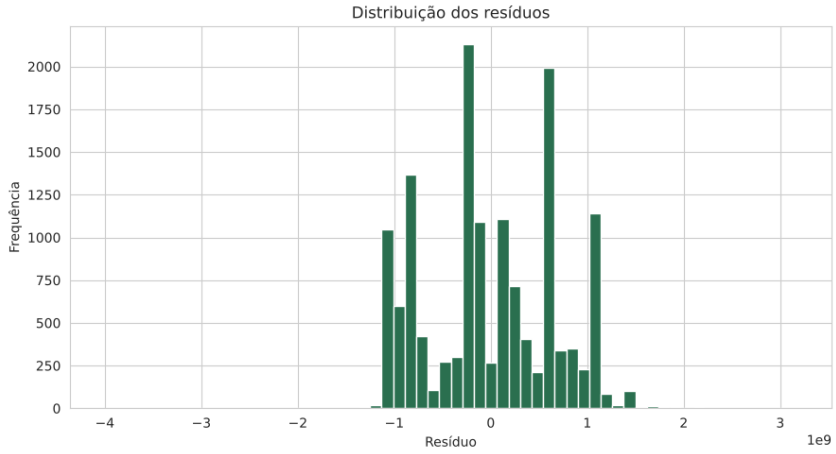


Figura 5. Distribuição dos resíduos.

Teste	Estatística	P-valor	Conclusão
Breusch-Pagan (heterocedasticidade)	2.620,0	< 0,0001	rejeita variância constante
Shapiro-Wilk (normalidade, amostra de 5.000)	0,961	< 0,0001	rejeita normalidade dos resíduos
Durbin-Watson (autocorrelação)	0,032	-	indica autocorrelação positiva forte

Os três testes formais confirmam o que os gráficos sugeriram. O teste de Breusch-Pagan rejeita a hipótese de variância constante, confirmando heterocedasticidade. O teste de Shapiro-Wilk rejeita a hipótese de normalidade dos resíduos. O valor de Durbin-Watson próximo de zero indica autocorrelação positiva forte, esperada em dados organizados por ano e depois por cenário, em que observações vizinhas tendem a se parecer mais entre si do que observações distantes. Nenhum desses resultados invalida o modelo, mas indicam que os erros-padrão e p-valores reportados pelo OLS devem ser interpretados com cautela, já que pressupõem resíduos independentes e com variância constante.

O fator de inflação da variância (VIF) do Resultado Líquido e do Ano ficou em torno de 4,37. Valores de VIF acima de 10 costumam ser considerados preocupantes, e acima de 5 já merecem atenção; o valor encontrado fica abaixo desse limite mais rígido, mas ainda indica alguma colinearidade entre as duas variáveis explicativas, o que reforça a cautela na leitura isolada do coeficiente do Resultado Líquido.

5. Limitações da análise

- Pooling de anos e cenários: o modelo foi ajustado com os 14.400 registros agrupados, sem considerar que cada ano tem sua própria dinâmica. O sinal negativo do coeficiente do Resultado Líquido é provavelmente um reflexo disso, e não uma relação de causa e efeito direta.
- Heterocedasticidade e não normalidade dos resíduos, confirmadas pelos testes de Breusch-Pagan e Shapiro-Wilk, tornam os p-valores e intervalos de confiança do modelo aproximados, não exatos.
- Autocorrelação dos resíduos, evidenciada pelo Durbin-Watson próximo de zero, compromete a validade formal dos testes de significância, mesmo que as estimativas dos coeficientes continuem válidas.

- Variáveis fora do modelo: apenas Resultado Líquido e Ano foram usados. Mais da metade da variação da Geração de Caixa não é explicada por elas, o que indica a relevância de outros fatores não incluídos, como capital de giro e timing de pagamentos e recebimentos.
- Relação linear assumida: a leve curvatura observada no gráfico de resíduos sugere que uma relação não linear poderia descrever melhor os dados, algo que poderia ser explorado em uma análise futura.
- Multicolinearidade moderada entre Resultado Líquido e Ano, evidenciada pelo VIF em torno de 4,4, dificulta isolar com total precisão o efeito individual de cada variável.

6. Síntese

O modelo de regressão ajustado explica cerca de 45% da variação da Geração de Caixa a partir do Resultado Líquido e do Ano da concessão, um ajuste moderado e estatisticamente significativo, mas longe de perfeito. O coeficiente do Ano confirma que a geração de caixa tende a crescer ao longo da concessão, enquanto o coeficiente negativo do Resultado Líquido chama atenção para o fato de que lucro contábil e caixa gerado não andam necessariamente juntos dentro de um mesmo ano, até porque a correlação simples entre as duas variáveis já é negativa.

Os diagnósticos mostraram que o modelo não respeita totalmente as premissas clássicas da regressão linear, o que é esperado em dados de simulação organizados por ano e cenário sem uma estrutura de painel propriamente dita. Ainda assim, o exercício cumpriu o papel desta entrega: explorar uma relação real entre variáveis financeiras, evitando o erro de montar um modelo tautológico a partir de variáveis quase idênticas entre si, e deixando registradas as limitações que qualquer leitura dos coeficientes precisa levar em conta.