Centro Universitário Álvares Penteado
Análise Inferencial de Dados

Entrega 02: Relatório de Análise de Regressão dos Dados

Objetivo: ajustar um modelo de regressão linear para explorar relações entre indicadores financeiros, interpretar os coeficientes, avaliar a qualidade do ajuste e registrar as limitações da análise.

Nomes:	**Professor:**	**Turma:**
Julia Pereira Godinho | RA: 26028796 Mariana Almeida Nascimento | RA: 22011051 Rafaela Florêncio Morais | RA: 25027460	Prof° Rodnil Lisboa	CCOMP 4

Objetivo

Este documento apresenta a segunda entrega da disciplina de Análise Inferencial de Dados, cujo objetivo é conduzir uma análise de regressão sobre os dados financeiros do projeto, dando sequência à análise descritiva realizada na entrega anterior. O relatório descreve a escolha das variáveis do modelo, o ajuste da regressão linear, a interpretação dos coeficientes, a avaliação da qualidade do ajuste, os diagnósticos realizados sobre os resíduos, uma verificação de sensibilidade e as limitações identificadas. Cada termo técnico é explicado na primeira vez em que aparece, e todos estão reunidos no glossário ao final.

1. Escolhendo as variáveis do modelo

Antes de ajustar qualquer modelo, foi feita uma análise de correlação entre os principais indicadores financeiros para evitar um erro comum: montar uma regressão entre variáveis que são, na prática, quase a mesma coisa escrita de formas diferentes. A medida usada é o coeficiente de correlação de Pearson, que varia de -1 a +1: perto de +1 as duas variáveis sobem juntas, perto de -1 uma sobe quando a outra desce, e perto de 0 não há relação linear.

Par de variáveis	**Correlação**	**Interpretação**
Receita x EBITDA	0,990	muito alta, quase identidade contábil
Receita x Resultado Líquido	0,992	muito alta, quase identidade contábil
Resultado Líquido x Geração de Caixa	-0,460	moderada e negativa, relação real a explorar
Ano x Geração de Caixa	-0,172	fraca, mas com padrão não linear ao longo da concessão

Receita, EBITDA e Resultado Líquido se correlacionam entre si acima de 0,99. Isso é esperado pela própria estrutura da demonstração de resultado: o EBITDA deriva da Receita e o Resultado Líquido deriva do EBITDA, então os três crescem praticamente juntos ao longo dos 12 anos da concessão. Usar uma dessas variáveis para prever outra resultaria em um R^2 artificialmente próximo de 1, sem revelar relação nenhuma, apenas reconstruindo uma identidade contábil.

A Geração de Caixa, por outro lado, apresenta uma correlação moderada e negativa com o Resultado Líquido e uma correlação fraca com o Ano, um padrão bem diferente do observado entre Receita, EBITDA e Resultado Líquido. Isso indica que a Geração de Caixa segue uma lógica própria, provavelmente ligada a itens que não passam diretamente pelo resultado contábil, como capital de giro e o momento dos desembolsos de caixa. Por esse motivo, o modelo escolhido para esta entrega foi:

$$\textbf{Geração de Caixa} = \beta_0 + \beta_1 \times \textbf{Resultado Líquido} + \beta_2 \times \textbf{Ano} + \textbf{erro}$$

Nesse modelo, a Geração de Caixa é a variável dependente (a que se quer explicar), o Resultado Líquido e o Ano são as variáveis explicativas, os β são os coeficientes estimados pelo modelo e o erro é a parte que o modelo não consegue explicar.

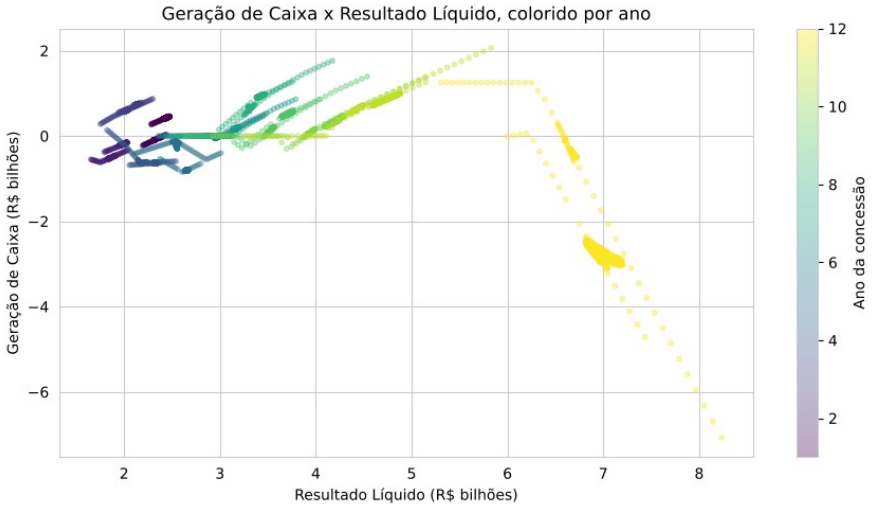


Figura 1. Geração de Caixa em função do Resultado Líquido, com a cor indicando o ano da concessão.

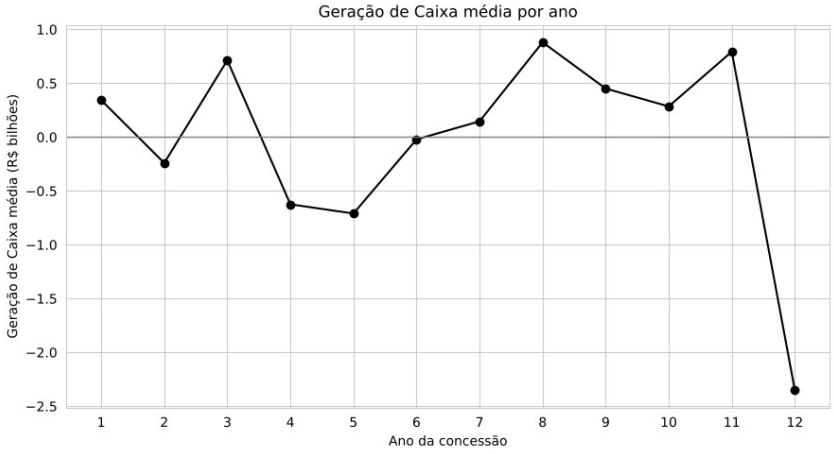


Figura 2. Geração de Caixa média por ano da concessão.

A Figura 1 não mostra uma única reta: os pontos se organizam em faixas por ano, e a inclinação dentro de cada faixa nem sempre é a mesma. Os pontos de cor mais clara, à direita, são do Ano 12, em que o Resultado Líquido é bem maior (cerca de R$ 6,9 bilhões) e a Geração de Caixa fica fortemente negativa. A Figura 2 confirma isso: a Geração de Caixa média oscila bastante de um ano para outro (positiva nos anos 1, 3, 7, 8, 9, 10 e 11, negativa nos anos 2, 4, 5 e 6) e despenca no Ano 12, em torno de -R$ 2,35 bilhões, ano de encerramento da concessão. Não existe, portanto, uma tendência simples de crescimento ao longo do tempo, e o Ano 12 se comporta de forma bem diferente dos demais.

2. Ajustando o modelo e interpretando os coeficientes

O modelo foi ajustado por mínimos quadrados ordinários (OLS, do inglês Ordinary Least Squares), método que escolhe os coeficientes de forma a tornar a menor possível a soma dos quadrados dos resíduos, isto é, das diferenças entre o valor real e o valor previsto. Foram usadas as 14.400 observações da base (1.200 cenários x 12 anos).

Variável	Coeficiente	P-valor	VIF
Intercepto	1,34 bi	-	-
Resultado Líquido	-0,928	< 0,0001	4,37
Ano	269,0 mi	< 0,0001	4,37

Um coeficiente indica quanto a Geração de Caixa muda, em média, quando aquela variável aumenta em uma unidade, mantendo a outra fixa. O intercepto é o valor esperado quando todas as variáveis explicativas são zero e não tem leitura prática isolada, serve apenas para ancorar a reta. O coeficiente do Resultado Líquido indica que, mantendo o ano fixo, cada real a mais de resultado líquido está associado, em média, a uma redução de cerca de 0,93 real na geração de caixa. O coeficiente do Ano indica que, mantendo o resultado líquido fixo, cada ano adicional está associado a um aumento médio de aproximadamente 269 milhões de reais.

O sinal negativo do Resultado Líquido chama atenção, porque seria razoável esperar que mais lucro significasse mais caixa gerado. A seção 5 mostra o motivo: dentro de cada ano, a relação entre Resultado Líquido e Geração de Caixa é positiva na maioria dos anos, e o sinal negativo geral aparece principalmente por causa do Ano 12, em que o Resultado Líquido é muito alto e a Geração de Caixa é muito negativa. Essa situação, em que a relação com os dados juntos é diferente (ou até oposta) à relação dentro de cada grupo, é conhecida como paradoxo de Simpson. Portanto, o coeficiente do Resultado Líquido não deve ser lido como "mais lucro reduz o caixa": ele resume uma mistura de efeitos de anos diferentes e é muito sensível ao Ano 12.

3. Qualidade do ajuste

Duas medidas resumem o quanto o modelo se ajusta aos dados. O R^2 é a proporção da variação da Geração de Caixa explicada pelo modelo, de 0 (não explica nada) a 1 (explica tudo). O R^2 ajustado é parecido, mas desconta o efeito de acrescentar variáveis ao modelo, o que permite comparar modelos com números diferentes de variáveis. O modelo apresentou R^2 de 0,447 e R^2 ajustado de 0,447, ou seja, explica cerca de 45% da variação da Geração de Caixa.

É um ajuste moderado: nem perto de 1, o que seria sinal de uma identidade contábil disfarçada (como ocorreria ao usar EBITDA no lugar do Resultado Líquido), nem perto de zero, o que indicaria ausência de relação. Pouco mais da metade da variação da Geração de Caixa fica fora do que as duas variáveis explicam, o que é esperado, já que a geração de caixa também depende de fatores como variação de capital de giro, descompasso entre pagamentos e recebimentos e comportamentos específicos de cada ano da concessão.

3.1 Testes de hipótese sobre o modelo

A regressão também pode ser lida como um conjunto de testes de hipótese. Para cada coeficiente, o teste t tem como hipótese nula (H0) que o coeficiente é zero, isto é, que a variável não ajuda a explicar a Geração de Caixa com a outra variável mantida fixa, e como hipótese alternativa (H1) que o coeficiente é diferente de zero. A estatística t é o coeficiente dividido pelo seu erro-padrão (a incerteza da estimativa). O valor-p é a probabilidade de obter um resultado tão extremo quanto o observado se H0 fosse verdadeira, e H0 é rejeitada quando o valor-p é menor que 0,05. O intervalo

de confiança de 95% (IC 95%) é a faixa onde o coeficiente verdadeiro provavelmente está. Para o modelo como um todo, o teste F tem como H0 que todos os coeficientes, exceto o intercepto, são zero, ou seja, que o modelo não explica nada além da média.

Variável	**Estatística t**	**Valor-p**	**IC 95%**	**Decisão**
Resultado Líquido	-104,2	< 0,0001	[-0,945; -0,910]	rejeita H0
Ano	78,3	< 0,0001	[262,2 mi; 275,7 mi]	rejeita H0
Modelo (teste F)	5.814,2	< 0,0001	-	rejeita H0

Nos dois testes t o valor-p é praticamente zero, então H0 é rejeitada para o Resultado Líquido e para o Ano, e os intervalos de confiança de 95% não incluem o zero. O teste F também rejeita H0, logo o modelo explica mais do que apenas a média da Geração de Caixa. Com 14.400 observações, porém, até efeitos pequenos produzem valores-p minúsculos, por isso o valor-p deve ser lido junto com o tamanho do efeito e o R^2. Como os diagnósticos a seguir mostram que as premissas do OLS não são totalmente atendidas, esses valores-p devem ser tratados como aproximados.

4. Diagnósticos do modelo

Além do R^2 e dos coeficientes, foram verificadas as premissas da regressão linear. A principal ferramenta são os resíduos, a diferença entre a Geração de Caixa real e a prevista pelo modelo. Se o modelo estiver bem especificado, os resíduos devem se comportar como ruído: sem padrão, com variância constante, distribuição próxima da normal e independentes entre si.

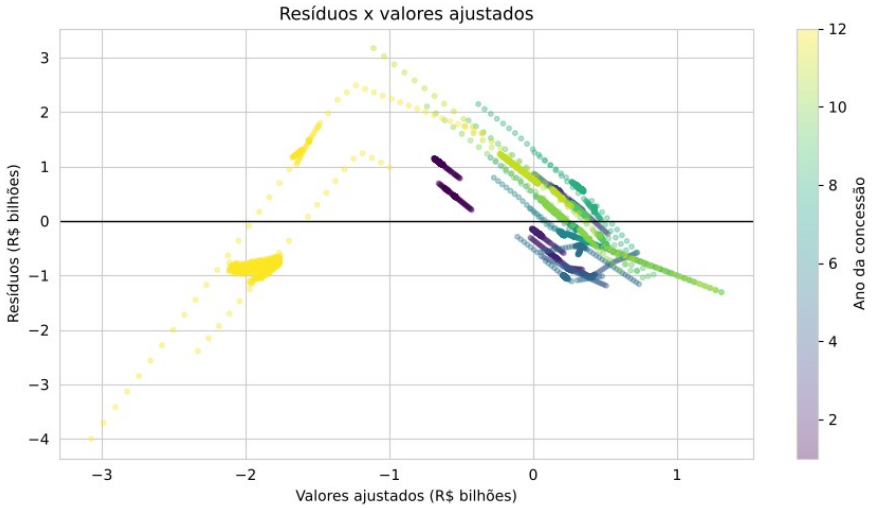


Figura 3. Resíduos em função dos valores ajustados (valores previstos pelo modelo), com a cor indicando o ano.

Em um modelo bem especificado, a nuvem da Figura 3 ficaria espalhada de forma uniforme ao redor da linha zero. Aqui o padrão é claro: os pontos formam faixas bem separadas, cada uma correspondente a um ano. Alguns anos ficam quase todos acima de zero (o modelo prevê menos caixa do que realmente ocorre) e outros quase todos abaixo (o modelo prevê mais). O modelo, com apenas Resultado Líquido e Ano em linha reta, não captura as particularidades de cada ano, o que indica que a relação não é bem descrita por uma reta única e que a variância dos resíduos muda conforme o valor ajustado.

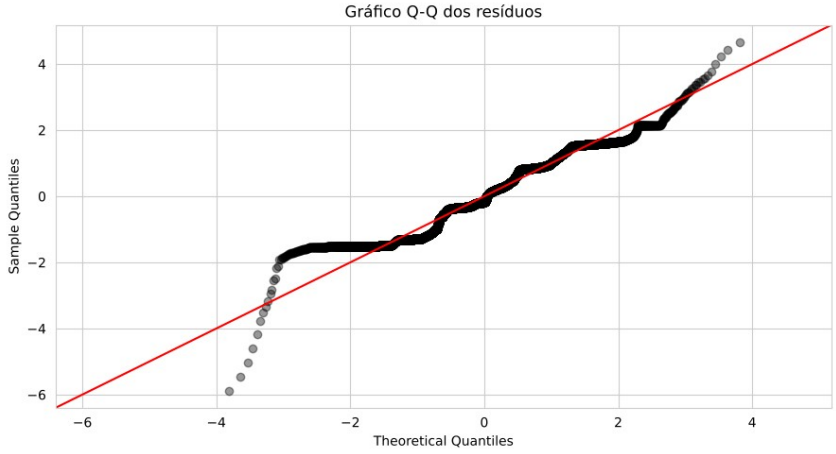


Figura 4. Gráfico Q-Q dos resíduos.

O gráfico Q-Q (Figura 4) compara os quantis dos resíduos com os de uma distribuição normal. Se os resíduos fossem normais, os pontos ficariam sobre a linha diagonal. Aqui eles formam degraus e se afastam da linha: há um trecho achatado no meio e uma cauda para baixo, à esquerda, com poucos pontos muito negativos, a maioria deles de cenários do Ano 12. A distribuição dos resíduos, portanto, não é normal.

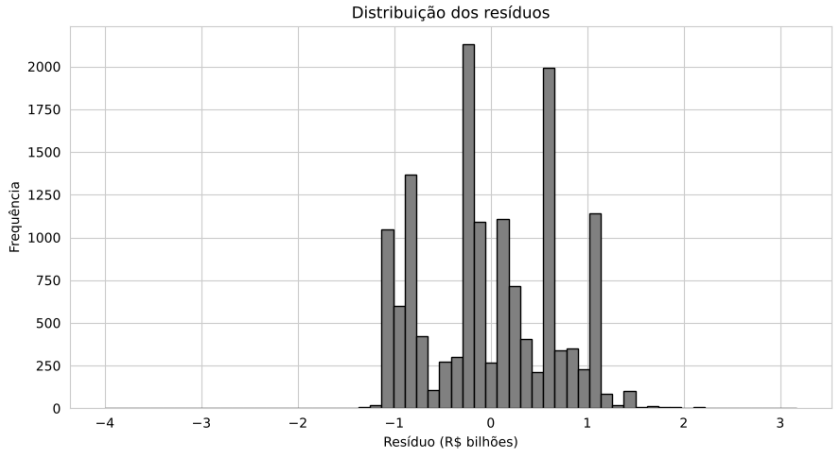


Figura 5. Distribuição dos resíduos.

O histograma (Figura 5) mostra o mesmo problema de outro ângulo: em vez de um único sino, aparecem vários blocos separados e uma cauda curta à esquerda.

Teste	**Estatística**	**P-valor**	**Conclusão**
Breusch-Pagan (heterocedasticidade)	2.620,0	< 0,0001	rejeita variância constante
Shapiro-Wilk (normalidade, amostra de 5.000)	0,961	< 0,0001	rejeita normalidade dos resíduos
Durbin-Watson (autocorrelação)	0,032	-	indica autocorrelação positiva forte

O teste de Breusch-Pagan verifica a heterocedasticidade. Homocedasticidade significa que os resíduos têm a mesma variância em todos os níveis do valor ajustado, e heterocedasticidade é o contrário; H0 é variância constante. O teste de Shapiro-Wilk verifica a normalidade, com H0 de que os resíduos seguem uma distribuição normal, aplicado aqui a uma amostra de 5.000 resíduos. O teste de Durbin-Watson mede a autocorrelação, isto é, o quanto um resíduo se parece com o vizinho: vai de 0 a 4, sendo que perto de 2 significa resíduos independentes, perto de 0 autocorrelação positiva forte e perto de 4 autocorrelação negativa forte.

Os resultados confirmam o que os gráficos sugeriram. O Breusch-Pagan rejeita a variância constante, o Shapiro-Wilk rejeita a normalidade e o Durbin-Watson, bem próximo de zero, indica autocorrelação positiva forte, esperada em uma base organizada por ano e depois por cenário, em que registros vizinhos pertencem ao mesmo ano e se parecem muito. Nenhum desses resultados impede o uso do modelo, mas eles indicam que os erros-padrão e valores-p do OLS devem ser interpretados com cautela, já que os testes t e F pressupõem resíduos independentes e com variância constante.

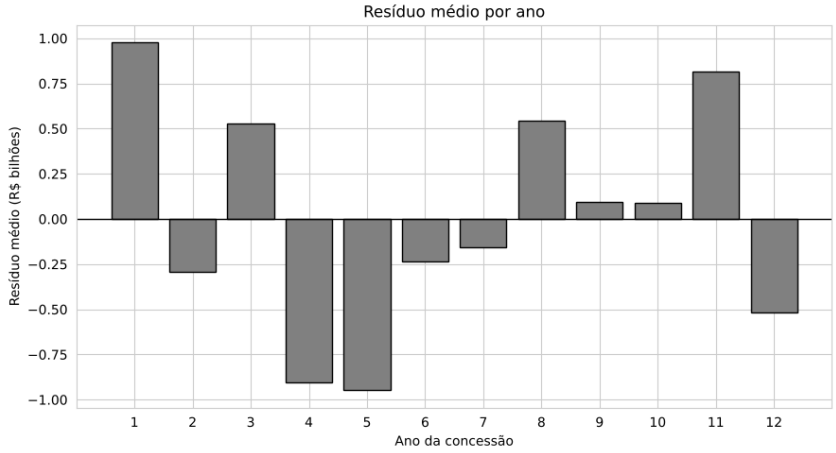


Figura 6. Resíduo médio por ano da concessão.

A Figura 6 deixa claro o que as faixas mostravam: se os resíduos fossem ruído, a média de cada ano ficaria perto de zero. Em vez disso, ela fica entre +R$ 0,5 bilhão e +R$ 1 bilhão em alguns anos (1, 3, 8 e 11) e perto de -R$ 1 bilhão em outros (4 e 5). Há uma parte sistemática, ligada ao ano, que o modelo não captura.

Por fim, o VIF (Fator de Inflação da Variância) mede a multicolinearidade, que ocorre quando as variáveis explicativas são muito parecidas entre si e o modelo tem dificuldade para separar o efeito de cada uma. Ele é calculado como $1 / (1 - R^2_j)$, onde R^2_j é o R^2 de prever aquela variável a partir das demais. VIF igual a 1 indica nenhuma colinearidade, acima de 5 já merece atenção e acima de 10 é preocupante. O VIF do Resultado Líquido e do Ano ficou em 4,37, abaixo do limite mais rígido, mas indicando colinearidade moderada (o Resultado Líquido também cresce com o Ano, com correlação de cerca de 0,88), mais um motivo para cautela na leitura do coeficiente do Resultado Líquido.

5. Verificação de sensibilidade

Como o sinal do coeficiente do Resultado Líquido contraria a intuição, foram feitas duas checagens. A primeira foi calcular a correlação entre Resultado Líquido e Geração de Caixa dentro de cada ano separadamente.

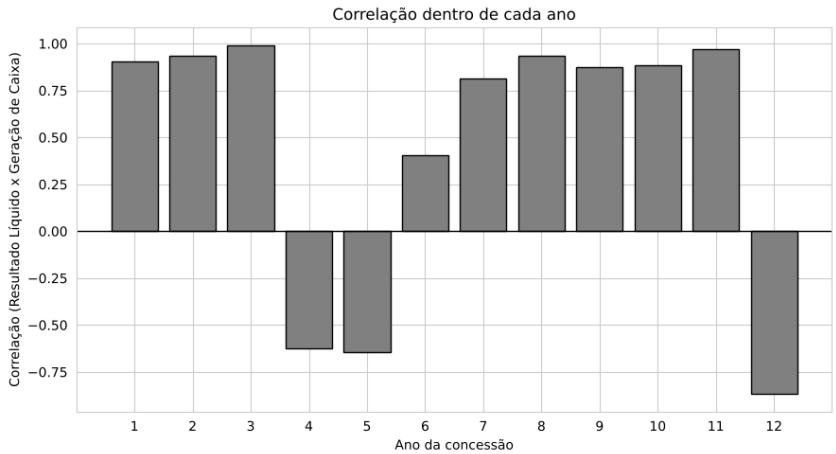


Figura 7. Correlação entre Resultado Líquido e Geração de Caixa dentro de cada ano.

Dentro de cada ano, a correlação é positiva em 9 dos 12 anos (entre 0,40 e 0,99), e só nos anos 4, 5 e 12 ela é negativa. A relação "mais lucro, mais caixa" existe, portanto, na maior parte do tempo, e

o sinal negativo do modelo geral vem da mistura entre anos. A segunda checagem foi ajustar o mesmo modelo sem o Ano 12.

Medida	**Todos os anos**	**Sem o Ano 12**
Coeficiente do Resultado Líquido	-0,928	0,730
Coeficiente do Ano	269,0 mi	-113,1 mi
R^2	0,447	0,301

Sem o Ano 12, o coeficiente do Resultado Líquido muda de sinal, de cerca de -0,93 para cerca de +0,73, e o coeficiente do Ano também muda de sinal, de +269 milhões para cerca de -113 milhões. O R^2 cai de 0,447 para cerca de 0,30. Os coeficientes do modelo original dependem, portanto, de um único ano, o de encerramento da concessão, e não são estáveis. Essa é a principal limitação da análise e mostra por que olhar apenas o R^2 e o valor-p não basta.

A terceira checagem testa se parte do problema é tratar o Ano como uma reta. Em vez de um número, o ano foi incluído como variável categórica (uma variável indicadora para cada ano), o que dá a cada ano o seu próprio nível de Geração de Caixa. Também foram comparados os erros-padrão do modelo original com erros-padrão agrupados por cenário, já que o mesmo cenário aparece nos 12 anos e esses registros não são independentes.

Modelo	**R^2**	**Coeficiente do Resultado Líquido**
Ano como número (modelo original)	0,447	-0,928
Somente o ano como categoria	0,875	-
Resultado Líquido + ano como categoria	0,881	-0,607
Resultado Líquido + ano como categoria, sem o Ano 12	0,956	+0,821

O resultado é bem informativo. Só o ano, como categoria, explica cerca de 87,5% da variação da Geração de Caixa, contra 44,7% do modelo com o Ano em linha reta, e adicionar o Resultado Líquido eleva o R^2 para apenas 88,1%, menos de 1 ponto percentual a mais. A Geração de Caixa é determinada principalmente pelo ano da concessão, de forma não linear, e não por uma tendência simples. O coeficiente do Resultado Líquido continua negativo com todos os anos e passa a positivo quando o Ano 12 sai, o que reforça que o sinal negativo vem do Ano 12. Os erros-padrão agrupados por cenário ficam muito parecidos com os originais (por exemplo, 0,0101 contra 0,0089 para o Resultado Líquido), então a dependência entre os anos de um mesmo cenário não muda as conclusões dos testes.

6. Limitações da análise

- Sensibilidade ao Ano 12: ao retirar o último ano, os coeficientes do Resultado Líquido e do Ano trocam de sinal e o R^2 cai de 0,45 para cerca de 0,30. Os coeficientes do modelo completo não devem ser lidos como efeitos estáveis.
- Pooling de anos e cenários: o modelo foi ajustado com os 14.400 registros agrupados (pooling), sem considerar que cada ano tem sua própria dinâmica, o que produziu o paradoxo de Simpson no sinal do Resultado Líquido.
- Heterocedasticidade e não normalidade dos resíduos, confirmadas pelos testes de Breusch-Pagan e Shapiro-Wilk, tornam os valores-p e intervalos de confiança aproximados, não exatos.

- Autocorrelação dos resíduos, evidenciada pelo Durbin-Watson próximo de zero e pelo resíduo médio por ano, compromete a validade formal dos testes de significância.
- Variáveis fora do modelo: apenas Resultado Líquido e Ano foram usados, e o Ano entra como número em linha reta, sem permitir que cada ano tenha seu próprio efeito. Quando o ano entra como categoria, o R^2 sobe de 0,45 para 0,88, o que mostra que a parte não explicada está ligada principalmente ao ano.
- Dependência entre registros do mesmo cenário: cada cenário aparece nos 12 anos, então as observações não são independentes entre si. Os erros-padrão agrupados por cenário mudam pouco, mas o ideal seria um modelo de dados em painel.
- Relação linear assumida: o modelo assume uma reta única, e os gráficos mostram que a relação muda de ano para ano.
- Multicolinearidade moderada entre Resultado Líquido e Ano (VIF em torno de 4,4) dificulta isolar o efeito individual de cada variável.

7. Conclusão

O modelo de regressão ajustado explica cerca de 45% da variação da Geração de Caixa a partir do Resultado Líquido e do Ano da concessão, um ajuste moderado e estatisticamente significativo, mas longe de perfeito. O coeficiente do Resultado Líquido é negativo (cerca de -0,93), o que contraria a intuição, e a investigação mostrou o motivo: dentro de cada ano a relação entre lucro e caixa é positiva na maioria dos anos, e o sinal negativo geral vem principalmente do Ano 12, em que o Resultado Líquido é muito alto e a Geração de Caixa é muito negativa. Sem o Ano 12, os dois coeficientes mudam de sinal e o R^2 cai para cerca de 0,30.

Os diagnósticos mostraram que o modelo não respeita as premissas clássicas da regressão linear: os resíduos se organizam por ano, não têm variância constante, não são normais e são autocorrelacionados. Ainda assim, o exercício cumpriu o papel desta entrega: explorar uma relação real entre variáveis financeiras, evitando o erro de montar um modelo tautológico a partir de variáveis quase idênticas, e registrando as limitações que qualquer leitura dos coeficientes precisa levar em conta. Para a Geração de Caixa, o ano da concessão importa mais do que uma tendência linear simples consegue representar: só o ano, tratado como categoria, explica cerca de 87,5% da variação, e o Resultado Líquido acrescenta menos de 1 ponto percentual a isso.

Glossário dos termos utilizados

Termo	O que significa
Regressão linear múltipla	Modelo que descreve uma variável (a dependente) como uma soma ponderada de outras variáveis (as explicativas) mais um erro.
OLS (mínimos quadrados ordinários)	Método que escolhe os coeficientes minimizando a soma dos quadrados dos resíduos.
Variável dependente e explicativa	A dependente é a que se quer explicar (Geração de Caixa). As explicativas são as usadas para explicá-la (Resultado Líquido e Ano).
Coeficiente	Quanto a variável dependente muda, em média, quando a explicativa sobe uma unidade, mantendo as demais fixas.
Intercepto	Valor esperado da variável dependente quando todas as explicativas são zero.
Resíduo	Diferença entre o valor real e o valor previsto pelo modelo.
Valor ajustado	Valor que o modelo prevê para cada observação.
Correlação de Pearson	Medida de relação linear entre duas variáveis, de -1 a +1.
R^2	Proporção da variação da variável dependente explicada pelo modelo, de 0 a 1.
R^2 ajustado	R^2 com desconto pelo número de variáveis do modelo.
Erro-padrão	Medida da incerteza da estimativa de um coeficiente.
Estatística t	Coeficiente dividido pelo erro-padrão. Mede quão longe de zero ele está.
H0 e H1	Hipótese nula (não há efeito) e hipótese alternativa (há efeito).
Valor-p	Probabilidade de obter um resultado tão extremo quanto o observado se H0 fosse verdadeira.
Intervalo de confiança (IC 95%)	Faixa de valores plausíveis para o coeficiente verdadeiro.
Teste F	Testa se o modelo, como um todo, explica algo além da média.
Multicolinearidade	Quando as variáveis explicativas são muito parecidas entre si.
VIF	Fator de Inflação da Variância. Mede a multicolinearidade: 1 é nenhuma, acima de 5 pede atenção, acima de 10 é preocupante.
Homocedasticidade e heterocedasticidade	Variância dos resíduos constante e não constante, respectivamente.
Breusch-Pagan	Teste de heterocedasticidade (H0: variância constante).
Normalidade	Quando os resíduos seguem uma distribuição normal, em formato de sino.
Shapiro-Wilk	Teste de normalidade (H0: resíduos normais).
Gráfico Q-Q	Compara os quantis dos resíduos com os de uma normal. Pontos sobre a diagonal indicam normalidade.
Autocorrelação	Quando resíduos de observações vizinhas se parecem entre si.
Durbin-Watson	Mede a autocorrelação: perto de 2 é independência, perto de 0 é autocorrelação positiva forte.
Pooling	Juntar todos os períodos e grupos em uma única regressão.
Paradoxo de Simpson	Quando a relação com os dados juntos é diferente, ou oposta, à relação dentro de cada grupo.
Variável categórica (indicadora)	Variável que representa grupos (aqui, cada ano), com um coeficiente próprio para cada grupo.
Erro-padrão agrupado (cluster)	Erro-padrão que considera que observações do mesmo grupo (aqui, o mesmo cenário em anos diferentes) são dependentes.
Sensibilidade	Verificar o quanto os resultados mudam ao alterar a amostra ou o modelo.